

PILL · 0.99

2026

04 - 05

● OBJECT DETECTION · PILL IDENTIFICATION

2-Stage 파이프라인으로 풀어낸 305-class fine-grained 분류 문제

경구약제 객체 인식 모델 개발

YOLOv26n + EfficientNetV2-S 기반 알약 탐지·분류 파이프라인의 설계, 실험, 검증 과정을 기록합니다.

Pill Detection & Classification - A 3-week engineering report

PILL · 0.97

TEAM

2팀 · Pill Detection

신호정 · 윤승준 · 김도혁
김소원 · 방찬우

PERIOD

2026.04.20 - 05.11

3주

STACK

YOLOv26n ·
EfficientNetV2-S
PyTorch · Optuna · Kaggle

SUBMISSION

Private Kaggle

GitHub Repository

TABLE OF CONTENTS

읽는
순서

27 pages 07 sections 19 min read

CH 01	우리는 알약의 이름이 궁금했습니다 배경 · 문제 정의 · 목표 재조정 · 팀 구성 · 일정	03 - 06
CH 02	이런 데이터로 시작했습니다 데이터 개요 · 클래스 분포 · 한계와 전략	07 - 09
CH 03	데이터를 이렇게 다듬었습니다 전처리 · 데이터 증강 (Stage 1·2) · 데이터셋 구성	10 - 13
CH 04	이렇게 설계했습니다 2-Stage 파이프라인 · Stage 1·2 모델 + 아키텍처 · 학습 곡선 · 결정 근거 6가지	14 - 20
- 21	INTERLUDE — 0.3979 → 0.96044 설계와 검증 사이, 7일의 호흡	21
CH 05	이렇게 실험했습니다 실험 결과 · HPO · 제출 기록 · 한계와 다음 단계	22 - 25
EP	우리의 3주, 다섯의 시선 팀원 다섯의 후기 — Epilogue	26
APX	APPENDIX — 데이터셋 배포 자동화 도구 프로그램 개발 의도 · 다운로드 링크 · QR 코드	27

▶ 본 보고서는 **판단 → 검증**의 순서로 구성되어 있습니다. CH04에서 6가지 설계 의사결정을 정리하고, CH05에서 그 판단이 실제 실험·Kaggle LB에서 어떻게 입증되었는지 기록합니다.

CHAPTER 01 · BACKGROUND

01 왜 알약 식별이 중요한 문제인가

처방전 없이 남은 알약, 약 봉투가 사라진 상황 — 일상에서 반복되는 이 작은 불확실성이 의료 사고로 이어집니다. 우리는 그 사실을 데이터로 확인했습니다.

"알약을 보고 이름을 바로 알 수 있는 사람이 몇이나 될까?"

팀 첫 회의에서 던져진 질문 하나가 이 프로젝트의 출발점이었습니다.

BACKGROUND — 데이터로 보는 문제 3 indicators

고령화

19.2%

65세 이상 인구 비율

다품목 복용 환자가 빠르게 증가하며 약물 오복용 위험이 누적됩니다.

통계청 · 2024 인구주택총조사

복약 부담

6.5종

만성질환자 1인 평균 복용 약

동시 복용 종 수가 많을수록 식별 오류·혼동 가능성이 비례 증가합니다.

건강보험심사평가원 · 2023

실제 사고


54.2%

약물 오복용 경험률 (60세 이상)

외형이 유사한 알약 간 혼동이 약물 사고의 주요 원인 중 하나입니다.

한국소비자원 · 2023 안전 실태조사

PROBLEM FLOW — 현 상황



ALTERNATIVES — 기존 해결책의 한계

약학정보원 앱

색상·모양·각인을 수동 선택해야 하며, 정확한 각인 텍스트를 알아야 식별 가능합니다.

● 수동 입력 · 오답률 높음

병원·약국 문의

운영 시간에만 가능하며, 야간·응급 상황에서는 접근 자체가 불가능합니다.

● 시간 제약 · 즉시 대응 불가

인터넷 검색

외형 묘사만으로 정확한 검색이 어렵고, 유사 약품 간 혼동 가능성이 높습니다.

● 낮은 신뢰도 · 오검색 위험

OUR SOLUTION

스마트폰 카메라 한 번으로 AI가 즉시 약 이름을 식별합니다

YOLO 기반 객체 탐지로 알약 위치를 찾고, CNN 분류기로 약품명을 식별하는 **2-Stage** 파이프라인. 시간·장소·전문 지식 제약 없이 누구나 즉시 답을 얻습니다.

GOAL PIVOT - 시작 전 한 번 더 점검

"모바일 이식까지"에서 "경량 모델 + 협업 역량"으로

R1

팀원 전원이 AI Engineer 실무 경험
부재

R2

Git 이해도 부족 — 협업 충돌 위험

R3

협업 도구 세팅 방향 불명확

INITIAL GOAL

알약 분류 모델을 iOS·Android에 이식하여 실서비스화.
사용자 접근성 극대화.



ADJUSTED GOAL

모바일 이식 가능한 경량 모델로 기술 범위 조정 + 팀 협업
역량 강화를 최우선 행동 지침으로 재설정.

PROJECT GOALS - 4 AXES 04

TECHNICAL

T

2-Stage 알약 탐지 + 분류 파이프라인

Stage 1 YOLOv26n으로 위치 탐지 → Stage 2 분류기로 약품명
식별. 두 단계로 역할 분리.

2-Stage

YOLO + CNN

PERFORMANCE ★

P

Kaggle E2E mAP 0.9 이상 달성

Stage 1 mAP@50 0.95+ · Stage 2 Top-1 0.88+ 단계 목표 위에
Kaggle Public LB 0.9 이상.

0.9+

→ 달성 0.96044

DATA

D

클래스 56종 데이터 수집·정제·증강

원본 56종 기준 외부 데이터 선별 병합. 증강 파이프라인으로
클래스당 학습 데이터 확보.

56

클래스 (원본)

LEARNING

L

ML 전 과정 경험 + 협업 역량 강화

데이터 수집부터 배포까지 전 사이클을 직접 구현. GitHub 기반 협업
프로세스 체득.

3W

팀 프로젝트 기간

SCHEDULE - 3 WEEKS 04.20 → 05.10

WEEK 01

04.20 - 04.25

데이터 수집 및 EDA

원본·외부 데이터셋 탐색, EDA 수행,
클래스 매핑 전략 수립

EDA

매핑

수집

WEEK 02

04.26 - 05.02

전처리 · 증강 · 베이스라인

YOLO 포맷 변환, 증강 파이프라인 구축,
베이스라인 학습·실험

전처리

증강

Baseline

WEEK 03 · FINAL

05.03 - 05.10

튜닝 · 최종 제출 · 보고서

하이퍼파라미터 튜닝, Kaggle 최종 제출,
보고서·발표자료 완성

HPO

Submit

Report

TEAM COMPOSITION

5

PEOPLE · 1 PROJECT

PM·모델·실험·데이터·분석

5개 파트 유기적 협력

각 팀원이 명확한 책임 영역을 가지되, GitHub PR 리뷰와 데일리 리포트를 통해 전체 진행 상황을 공유하는 구조로 운영했습니다.



신호정

PM · TECH LEAD

아키텍처 리뷰 · 기술 의사결정
품질 게이트 · 일정 관리 · 문서화 총괄

LEAD



윤승준

MODEL ENGINEER

모델 구현 및 학습 파이프라인
scripts/ 1차 구현 · 모델 버전 관리

ME



김도혁

EXPERIMENTATION LEAD

실험 설계 · 실행 · 로깅
결과 집계 · 비교 분석 · HPO 탐색

EL



김소원

DATA ENGINEER

데이터 전처리 파이프라인
증강 전략 수립 · 클래스 매핑 · EDA

DE



방찬우

REPORT & ANALYSIS

EDA · 결과 시각화
보고서 디자인 · 발표자료 총괄

RA

COLLABORATION PRACTICES 3 systems



데일리 리포트

매일 작업 내용·완료도·이슈를 공유.
GitHub Discussion 기반으로 익일 시작 전 전원 동기화.



GitHub PR 리뷰

모든 코드는 PR을 통해 리뷰 후 병합.
PM이 품질 게이트 역할을 담당하여 일관성 유지.



데이터셋 자동 배포

PM 제작 업로더·다운로더로 **Drive → Colab 세팅 자동화**. 수동 배포 실수 차단.


PROJECT TIMELINE · 2026.04.20 - 05.10

21

21일, 6개 워크스트림, 6번의 Kaggle 제출


데이터 정비 → 베이스라인 → 모델 교체 → HPO → Final Model.

각 워크스트림이 병렬로 흐르되, 핵심 마일스톤에서 모이는 구조로 운영했습니다.



WEEKLY BEAT 3주의 리듬

3 weeks · 3 phases



CRITICAL PATH 시간 순으로 본 6개 핵심 의사결정

CH 04 · 7 → CH 05 검증




02 232장에서 6,259장으로, 56클래스에서 305클래스로

원본 학습 데이터의 절대량이 부족했습니다. 외부 데이터를 선별·병합해
클래스 커버리지를 확보하되, 클래스당 평균 10장 수준의 long-tail 환경은
그대로였습니다.

DATA COMPOSITION 3 sources



SCALE AT A GLANCE



SOURCE BREAKDOWN

SOURCE	설명	IMAGES	CLASSES	TAG
원본 (Raw)	976×1280 · 파란 단색 배경 · 멀티 객체. COCO JSON 포맷 → YOLO txt 변환 필요. 이상치 1건 (bbox 좌표 범위 초과).	232	56	CORE
External 1차	640×640 · 다양한 실제 환경 배경 · 단일 객체 중심 (center bias). 319cls · 이상치 0건.	3,851	+182	EXT
External 2차 (Kaggle 보강)	Kaggle 평가 클래스 누락분 보강 · 305cls 재구성의 핵심.	2,176	+67	FIX
Total	Stage 2 분류기 학습용 통합 데이터셋	6,259	305	FINAL

! Stage 1과 Stage 2의 데이터셋이 다릅니다. Stage 1은 raw+external 통합 4,977장(pill 단일 클래스, 온라인 증강만)으로 학습, Stage 2는 통합 6,259장(305cls, 오프라인 증강)으로 학습.

i 도메인 특성: 클래스 간 시각적 유사성이 높고(모양·색상·크기 유사), 알약 표면 각인이 존재해 Flip 증강 시 오인식 위험. 촬영 시 임의 방향 → 회전 불변성 필수.

2-2 회소 클래스가 절반, 밀집 클래스가 일부

305 classes · long-tail

MIN

3

최소 샘플 수
가장 회소한 클래스

MEDIAN

8

중앙값
전체의 절반이 8장 이하

MEAN

10.3

평균 샘플 수
증강 전 기준


MAX

38

최대 샘플 수
가장 밀집한 클래스

클래스별 이미지 수 분포 (305 classes)

x축: 샘플 수 구간 · y축: 해당 구간에 속한 클래스 수 · 전형적 long-tail 분포



TAIL · 회소

174 cls (≤8장)

전체의 57%

MID · 중간

102 cls (9-16장)

전체의 33%

HEAD · 밀집

29 cls (17-38장)

전체의 10%

IMPLICATIONS — 분포가 설계에 미친 영향

STAGE 1 분리

단일 YOLO로는 학습 신호 부족

305cls × 평균 10장에서 단일 YOLO가 위치+분류를
동시 수행하면 클래스당 학습 신호가 희박. **2-Stage로 역할 분리**해
Stage 1은 1-class 탐지에 집중.

사전학습 전이

소량 데이터를 ImageNet 전이로 보완

클래스당 10장 수준에서 from-scratch 학습은 무리.
ImageNet 사전학습 가중치 전이가 사실상 필수 조건이었습니다.

2-3 3가지 한계, 3가지 대응

limitations × strategies

01

LIMIT · 절대량 부족

클래스당 평균 10장

305cls fine-grained 분류로는 학습 신호가 희박. 모델이 클래스 간 미세한 외형 차이를 학습하기에 충분하지 않은 양.

→

STRATEGY · 외부 데이터 병합

External 6,027장 선별 합류

크기·색조·라벨링 표준 정렬 후 통합. 305cls 재구성으로 클래스 커버리지를 확보하면서 동시에 학습 데이터 규모도 28배 확대.

02

LIMIT · 클래스 불균형

Tail 174cls (전체 57%)

8장 이하 희소 클래스가 절반 이상. 단순 학습 시 Head 클래스로 편향되며 Tail 클래스에 대한 인식이 무너지는 long-tail 위험.

→

STRATEGY · 증강 + 사전학습

ImageNet 전이 + 강한 증강

사전학습 가중치로 일반 시각 표현 확보, 그 위에 회전·색상·크롭 증강으로 클래스당 유효 샘플 수 확대. Tail 클래스 강화 효과.

03

LIMIT · 평가 불일치

학습 305cls vs Kaggle 57cls

Kaggle은 57cls만 평가. 학습은 305cls로 일반화 시키되, 평가 클래스 누락 시 점수가 폭락하는 구조.

→

STRATEGY · EXTERNAL 2차 보강

Kaggle 평가 누락분 추가 수집

초기 검증에서 누락된 평가 클래스 식별 → External 2차 데이터셋(2,176장)으로 보강. 305cls 재구성의 핵심이 된 단계.

STRATEGY OUTCOME

"문제는 데이터의 양이 아니라 데이터의 다양성과 평가 정렬이었다"

세 가지 대응을 동시에 적용한 결과, Stage 1 mAP@50 0.9947(val) 달성. 데이터의 양적 부족을 다양성과 평가 정렬로 우회한 전략이 통한 것을 첫 베이스라인 단계에서 확인.

EVIDENCE 대응의 정량 효과

3 strategies · 3 metrics

EFFECT 01 · DATA SCALE

232 → 6,259 장

External 합류로 전체 데이터셋 28배 확대. 클래스 평균 10.3장 확보.

EFFECT 02 · TAIL ROBUSTNESS

Top-5 0.9745

ImageNet 전이 + 차등 증강으로 Tail 클래스 인식 안정화. Top-1 대비 +9p 헤드룸 확보.

EFFECT 03 · EVAL ALIGNMENT

57 / 57 cls cover

External 2차 보강으로 Kaggle 평가 클래스 누락 0건. 최종 LB 0.96044 기반.

DATA-STAGE LESSONS

"고품질 외부 데이터 ≠ 우리 도메인 데이터" — 표준 정렬 단계가 외부 데이터 활용의 실제 비용.

"학습 분포보다 평가 분포가 우선" — 305cls 학습은 Kaggle 57cls를 모두 포함할 때만 의미를 가진다.


03 데이터를 모델이 먹을 수 있는 형태로

이중 소스(원본/외부 1차/외부 2차)의 데이터를 일관된 포맷·라벨링으로 정렬하고, YOLO·Stage 2 두 모델이 각각 학습할 수 있는 형태로 변환했습니다.

PREPROCESSING PIPELINE - 4 STAGES

01 · COLLECT 데이터 수집·검증 원본 232 + 외부 6,027 통합. 이상치 1건 제외 (bbox x=6567, 정상 너비 976).	02 · NORMALIZE 정규화·라벨 정렬 크기·색조·네이밍 통일. 클래스 ID 매핑 테이블 작성.	03 · CONVERT 포맷 변환 Raw COCO JSON → YOLO txt. bbox 좌표 정규화 + class_id 매핑.	04 · SPLIT 학습/검증 분할 stratified 분할로 클래스별 비율 보존. seed 고정.
---	---	--	--

FORMAT CONVERSION · YOLO ANNOTATION



STAGE-SPECIFIC DATASETS

STAGE 1 · 탐지기용 단일 클래스 탐지 데이터셋 A 모든 알약 라벨을 class_id = 0 (pill)으로 단일화. 위치 탐지에만 집중. B 학습/검증/테스트 split (8:1:1): train 3,981 / val 497 / test 499. raw+external 통합 4,977장. YOLO26 내장 온라인 증강만 사용, 별도 오프라인 증강 미적용. C 이미지 크기 640×640으로 통일 (YOLO 기본 입력).
--

3-2 소량 데이터 환경에서 일반화 성능을 끌어올리는 도구

9 augmentations

AUGMENTATION PHILOSOPHY

"클래스 정체성을 해치지 않는 선에서, 다양한 촬영 조건을 학습 데이터로"

GEOMETRY

기하 변환

위치·각도·크기 변동 시뮬레이션

COLOR

색상 변환

조명·화이트밸런스 차이 흡수

MIX

혼합 증강

YOLO mosaic — 4장 합성으로 다양성 확보

STAGE 1 · ONLINE AUGMENTATIONS — YOLO26 내장 9 transforms



GEOMETRY

Rotation

degrees = ±15°

알약 회전. 격자 정렬되지 않은 자연스러운 촬영 각도 학습.



GEOMETRY

Translate

translate = 0.1

이미지 내 위치 이동. 알약이 프레임 어디에 있어도 학습.



GEOMETRY

Scale

scale = 0.5

크기 변환. 카메라 거리에 따른 알약 크기 변화 대응.



GEOMETRY

Flip · Horizontal

flip_lr = 0.5

좌우 반전. Stage 1은 위치 탐지만 수행하므로 각인 반전 무관.



COLOR

HSV — Hue

hsv_h = 0.015

색상 각도. 조명 색온도 차이 흡수.



COLOR

HSV — Saturation

hsv_s = 0.7

채도 변환. 카메라·필터 차이로 인한 색상 강도 변동 학습.



COLOR

HSV — Value

hsv_v = 0.4

밝기 변환. 다양한 조명 환경 (실내/실외) 대응.



MIX

Mosaic

mosaic = 1.0

YOLO 핵심 증강. 4장을 격자 합성으로 한 이미지에 다양성 압축.



MIX

Erasing

erasing = 0.4

랜덤 영역 마스킹. 가림·간섭 상황에 대한 강건성 확보.

EFFECT — 검증 결과 (STAGE 1 MAP@50)

WITHOUT AUGMENTATION

0.872

증강 미적용 베이스라인. Tail 클래스에서 큰 성능 손실.

WITH 9 AUGMENTATIONS

0.9947

증강 적용 후 +12.3%p. Tail 클래스 인식까지 안정화.

i 다음 페이지: Stage 2 분류기를 위한 오프라인 증강 전략 — 알약 도메인 특화 규칙(Flip 제외)과 클래스 불균형 해소를 위한 구간별 차등 증강 정책.

3-3 분류기를 위한 도메인 특화 오프라인 증강

offline augmentation

STAGE 2 AUGMENTATION PHILOSOPHY

"각인을 보존하고, 클래스 정체성을 해치지 않는 변환만"

분류기는 알약 표면의 미세한 시각 단서(각인 텍스트·로고·색상)를 학습한다. Stage 1과 달리 Stage 2에서는 이 단서를 훼손하는 변환을 엄격히 배제하고, 클래스 불균형 해소를 위한 차등 증강 정책을 별도로 운영했다.

RULE 01 · DOMAIN ALIGNMENT — 알약 도메인 특화 변환 선택 기하 변환 정책

EXCLUDED

Flip (좌우/상하 반전)

알약 각인은 좌우 반전 시 판독 불가능 → 클래스 정체성 훼손. Stage 1(위치 탐지)에서는 안전하지만 Stage 2(분류)에서는 절대 사용 금지.
예: "ABC" → "CBA" 거울상

ACTIVE

Rotation (회전)

실제 촬영 시 알약은 임의 방향으로 놓이므로 회전 불변성 학습이 필수. 각인은 회전해도 글자 형태가 보존되어 안전한 변환.
±180° 범위 자유 회전

ACTIVE

Color · Brightness

조명·카메라 화이트밸런스 차이 흡수. 각인 형태는 보존되므로 안전. 다양한 촬영 환경에 강건한 모델로 만드는 핵심 변환.
HSV jitter · brightness ±20%

RULE 02 · CLASS BALANCING — 원본 데이터 수 기준 차등 증강 불균형 해소

원본 6,259장은 클래스당 분포가 불균등(평균 10.3장, Tail 클래스는 1~3장 수준). 단순 균등 증강은 Head 클래스가 과도하게 늘어나 학습 신호가 더 한쪽으로 쏠림. 따라서 **원본 샘플 수가 적은 클래스일수록 증강 배율을 크게** 적용했다.

TIER A · TAIL

1~5장 클래스

증강 배율 ↑↑↑

샘플 부족이 가장 심각. 회전·색상·crop 다양화로 강하게 보강.

TIER B · MID

6~15장 클래스

증강 배율 ↑↑

중간 구간. 균형 잡힌 증강으로 클래스 안정성 확보.

TIER C · HEAD

16+ 클래스

증강 배율 ↑

상대적으로 풍부. 과적합 방지 수준의 약한 증강.

RESULT — 증강 후 데이터셋 규모

ORIGINAL

6,259 장

305 클래스 · 평균 10.3장/클래스

→

AUGMENTED

17,521 장

평균 약 2.8배 확대 · Tier별 차등

→

SPLIT

7 : 1.5 : 1.5

train 15,525 / val 824 / test 1,172

i Stage 1과의 차이: Stage 1은 YOLO26 내장 온라인 증강(9 transforms)만 사용해 학습 시 매번 새 변환 적용. Stage 2는 학습 전에 오프라인으로 증강 이미지를 미리 생성·저장한 후 학습에 투입.

3-4 두 모델, 두 데이터셋, 하나의 학습 흐름

2 datasets

6,259
TOTAL IMAGES

FINAL DATASET COMPOSITION

232 (원본) + 6,027 (외부) = 6,259장

Stage 1은 raw+external 통합 4,977장 (단일 클래스)으로 위치 탐지를 학습하고 (온라인 증강만, 8:1:1), Stage 2는 통합 6,259장 (305 클래스)을 오프라인 증강해 분류를 학습 (7:1.5:1.5). 두 모델이 서로 다른 데이터셋으로 학습되는 구조.

STAGE 1

Localization

탐지 데이터셋 · YOLO

SOURCE	통합 4,977장 (Raw+Ext)
CLASSES	1 · pill (single class)
IMAGE SIZE	640 × 640 px
FORMAT	YOLO .txt (정규화 bbox)
ANNOTATION	4,977 images

Train · 3,981 (온라인 증강)

497

499

■ Training ■ Validation ■ Test

STAGE 2

Classification

분류 데이터셋 · CNN

SOURCE	통합 6,259장 (Raw + Ext)
CLASSES	305 · fine-grained
IMAGE SIZE	224 × 224 px (cropped)
FORMAT	PIL Image + class_id
AVG / CLASS	10.3 images

Train · 15,525 (오프라인 증강)

824

1,172

■ Training ■ Validation ■ Test

BUILD PROCESS 3 stages

STEP 01

클래스 매핑 테이블 생성

원본/외부 1차/외부 2차 클래스명을
305cls 통합 ID 체계로 매핑.
JSON 매핑 파일 작성.

STEP 02

Stage 1-2용 분리 변환

Stage 1은 원본만, single class.
Stage 2는 통합 데이터셋, 305 class.
두 변환 파이프라인 별도 운영.

STEP 03

Drive 자동 배포

PM 제작 도구로 데이터셋 zip →
Drive 업로드 → Colab에서
자동 다운로드. 수동 배포 실수 차단.

04 "위치를 찾는 일"과 "이름을 맞추는 일"의 분리

단일 모델이 305cls × 평균 10장의 데이터로 위치+분류를 동시 해결하기는 어렵다고 판단했습니다. **탐지와 분류를 분리**하는 것이 학습 신호를 집중시키는 가장 합리적 선택이었습니다.

PIPELINE ARCHITECTURE 2-stage



WHY 2-STAGE - 단일 모델 VS 2-STAGE

단일 모델 가설

YOLO만으로 305cls 한 번에 처리

탐지+분류를 한 모델로 풀 수 있지만, **305cls × 평균 10장**이라는 학습 환경에서 fine-grained 분류 성능이 무너집니다. 시도 결과 mAP가 의미 있는 수준에 도달하지 못함.

2-STAGE 가설

탐지 + 분류 역할 분리

Stage 1은 **1-class 탐지**로 학습 신호 집중 (mAP@50 0.99+).
Stage 2는 **cropped image의 분류**에만 집중하여 ImageNet 사전학습 효과 극대화.

ARCHITECTURE COMPARISON

기준	단일 YOLO (305CLS)	2-STAGE (YOLO + CNN)
학습 신호	위치+305cls 동시 — 분산	단일 클래스 탐지에 집중 + 분류 별도
사전학습 활용	YOLO COCO 가중치만	YOLO COCO + ImageNet 분류기
실험 가능성	Stage 1:2 통합 변경만 가능	Stage별 독립 교체 — A/B 테스트 용이
예상 결과	mAP 0.5 미만 추정	Stage 1 0.99 · Stage 2 Top-1 0.88+ 가능

4-2 탐지에만 집중, 최신 경량 YOLO 채택

Stage 1 · Localization

DETECTION BACKBONE
YOLOv26n
Single-class pill localization

MAP@50 (VAL)	MAP@50 (TEST)	MAP@50-95 (VAL)	PRECISION	RECALL
0.9947	0.9950	0.8718	0.9963	0.9826

TRAINING CONFIGURATION 9 hps

MODEL
yolo_v26n.pt
Ultralytics 사전학습 가중치

IMAGE SIZE
640 × 640
YOLO 표준 입력 크기

BATCH SIZE
16
Colab T4 메모리 한계 기준

EPOCHS
100
조기 종료 patience = 20

OPTIMIZER
SGD
YOLO 기본 — momentum 0.937

LR0
0.01
초기 학습률 · cosine schedule

AUGMENTATION
9 transforms
CH03 참조 · mosaic 포함

PATIENCE
20
val mAP 정체 시 종료

SEED
42
메인 시당 고정 (W2) · 위커 시당 미완

WHY YOLOV26N — 선택 근거 3 reasons

01
**단일 클래스 탐지에
충분한 용량**
nano 모델로도 pill 단일 클래스에는
over-spec. 학습·추론 속도 우위.

02
최신 버전의 안정성 + 가용성
Ultralytics가 YOLOv26 시점에
안정적으로 maintain하는 가장 최신
가중치.

03
모바일 이식 가능 경량 모델
목표 재조정 시 명시한 "경량 모델"
조건 충족. nano 변형이
모바일 이식 친화적.

DETECTION RESULT — STAGE 1 실제 탐지 결과

Stage 1 결과 — YOLOv26n bbox 탐지

raw_K-003351-013900-
3개 탐지

raw_K-003351-031863-
3개 탐지

raw_K-003351-020014-
4개 탐지

raw_K-003351-018357-
3개 탐지

YOLOv26n bbox 탐지 — 다양한 형태·크기의 알약을 0.95+ 신뢰도로 탐지

PILL DETECTION · TEAM 02 · 2026

15


4-3 YOLOv26n — NMS-Free 단일 스테이지 탐지기

architecture & training

MODEL OVERVIEW

YOLOv26은 Ultralytics가 2026년에 공개한 단일 스테이지 객체 탐지 모델. 한 번의 순전파(forward pass)로 위치와 클래스를 동시에 예측. 이전 YOLO 시리즈 대비 세 가지 핵심 변경으로 추론 속도와 학습 안정성을 동시에 향상.

ARCHITECTURE DIAGRAM 그림 1: YOLOv26 모델



KEY INNOVATIONS — 이전 YOLO 대비 핵심 변경 3 changes

01

INFERENCE

NMS-Free 추론

비최대억제(NMS) 후처리 없이 직접 예측.
추론 속도 향상 + end-to-end 파이프라인 단순화.

02

BACKBONE

SPPF 내 shortcut 연결

Spatial Pyramid Pooling Fast 내부에
shortcut 경로 추가. 고수준 의미 표현 최적화
안정화.


03

LOSS

ProgLoss + STAL

학습 초기에 단순한 손실에서 점진적으로 복잡한
손실로 전환 → 수렴 안정성 향상.

STAGE 1 LEARNING CURVE 그림 5: 학습 곡선



i 빠른 수렴 — Best epoch 20. mAP@50이 epoch 5 이내에 0.95+에 도달,
epoch 20에서 0.9947로 포화. 단일 클래스(pill) 탐지 task 자체가 단순해
Nano 모델로도 충분.

✓ **선정 이유.** Nano 모델로도 mAP@50 0.9947 달성, Ultralytics 생태계
(ONNX export, 증강) 그대로 활용 가능 → 개발 속도 측면에서 유리.

4-4 세 분류 모델 비교 끝에 EfficientNetV2-S 채택

Stage 2 · Classification

CLASSIFICATION BACKBONE

EfficientNetV2-S

305-class fine-grained pill ID

GT TOP-1

0.8883

GT TOP-5

0.9745

KAGGLE LB ★

0.96044

PARAMS

21.46M

BACKBONE EVOLUTION — 세 후보 비교

INITIAL — TRIED

ResNet50

25.56M params

0.8750

GT Top-1 · baseline



TRIED — LIGHTER

EfficientNet-B2

9.11M params

0.8932

GT Top-1 · 경량 시도



FINAL · SELECTED

EfficientNetV2-S

21.46M params

0.8883

GT Top-1 · adopted

TRAINING CONFIGURATION

PRETRAINED

ImageNet 1k

timm 사전학습 가중치 전이

INPUT SIZE

224 × 224

bbox crop → resize

BATCH SIZE

32

Colab T4 GPU 기준

LR0 ★

0.0003

최종 결정값 — Decision 04 참조

OPTIMIZER

AdamW

weight_decay = 0.05

SCHEDULER

CosineLR

최종 lr → lr0 × 0.01

EPOCHS

50

조기 종료 patience = 10

LOSS

CrossEntropy


label smoothing = 0.1

AUGMENT

Custom 5

RandomResizedCrop · ColorJitter 등

E2E RESULT — 2-STAGE 파이프라인 최종 결과

2-Stage 파이프라인 최종 결과
bbox + 약품명 + 신뢰도


bbox + 약품명 + 신뢰도 — Stage 1 탐지 → Stage 2 분류 완료

4-5 세 가지 백본(Backbone) 구조와 선택의 근거

3 backbones

Stage 2는 Stage 1이 잘라낸 알약 이미지를 305개 클래스 중 하나로 분류한다. 우리는 세 가지 모델(Backbone)을 순차적으로 실험했고, 각각의 구조적 특징과 선정 근거는 다음과 같다.

BACKBONE 01 — RESNET50 (베이스라인) 그림 2 · Microsoft Research, 2016



잔차 신경망 (Residual Network). 깊이 50층 구조에 **Skip Connection**을 도입해 gradient 소실 문제를 해결. ImageNet 대규모 사전학습 가중치를 전이해 사용.

PARAMS 25.56M

RELEASED 2016

ROLE BASELINE

선정 이유 ▶ 안정적 baseline · 백본 교체 실험의 비교 기준점

BACKBONE 02 — EFFICIENTNET-B2 (중간 실험) 그림 3 · Google Brain, 2019



Compound Scaling. 네트워크의 깊이·폭·입력 해상도를 균형 있게 키우는 방식. **MBConv**(Inverted Residual) 블록과 **SE**(Squeeze-and-Excitation) 어텐션을 결합해 채널별 중요도 학습.


PARAMS 9.11M

RELEASED 2019

VS R50 ~ 1/3

선정 이유 ▶ 파라미터 효율 高 · 소량 데이터 환경 과적합 위험 감소

BACKBONE 03 — EFFICIENTNETV2-S (최종 채택) 그림 4 · Fused-MBConv 하이브리드



Fused-MBConv 도입. 기존 MBConv의 Depthwise Conv를 제거하고 일반 Conv 3×3으로 대체해 GPU/TPU 학습 효율 향상. 초기 레이어 (Stage 0~3)에 Fused 적용, 후기 레이어(Stage 4~6)에는 기존 MBConv+SE 유지하는 혼합 구조.

PARAMS 21.46M

LR0 FINAL 3e-4


BEST EP 87

선정 이유 ▶ B2보다 강한 표현력 · lr0 조정 후 best epoch 32~87 · Kaggle 0.96044 (전체 최고)

4-6 네 실험의 결과, 왜 V2-S(lr=3e-4)였는가

curve & metrics

STAGE 2 LEARNING CURVE - EFFICIENTNETV2-S (FINAL · LR=3E-4) 그림 6



i Best Top-10.8956 @ epoch 87. Train loss는 5.5 → 3.3 수준으로 안정적 감소, Val Top-1은 0.85 부근에서 epoch 87에 0.8956로 최고치 갱신. 최고 성능에 가까워졌으나 추가 학습 여지가 남아있는 곡선.

! 학습 시간 고려해 최종 선정. 225분 학습 후 곡선이 plateau에 근접 — 추가 학습 여지가 있으나 시간 대비 한계 효용이 작아 해당 시점에 최종 모델로 확정.

COMPLETE COMPARISON - 4 실험 결과 internal test set + Kaggle LB

백본	TOP-1	TOP-5	PARAMS	학습 시간	KAGGLE LB	RANK
ResNet50	0.8750	0.9612	25.56M	197분	0.90845	BASE
EfficientNet-B2	0.8932	0.9697	9.11M	157분	0.94731	EFF
V2-S (lr=6.45e-4)	0.8726	0.9563	21.46M	221분	0.95028	HPO
V2-S (lr=3e-4)	0.8883	0.9745	21.46M	225분	0.96044	FINAL

METRIC DEFINITION

Top-1 정확도

모델이 1순위로 예측한 클래스가 정답인 비율.

METRIC DEFINITION

Top-5 정확도

상위 5개 예측 중 정답이 포함된 비율.

METRIC DEFINITION

Params

모델 복잡도 · 추론 속도 · 메모리에 영향.

⚠ **재현성 주의:** 위 내부 Top-1·Top-5 지표는 DataLoader 워커 시딩 누락(W10)으로 인해 매 실행마다 소폭 변동 가능. Kaggle LB는 실제 제출 결과이므로 영향 없음. 자세한 내용은 4-7 설계 의사결정 + 5-4 한계와 다음 단계 참조.

4-7 3주를 지탱한 여섯 개의 판단

6 decisions · CH05에서 검증

WHY WE RECORD DECISIONS

"좋은 실험은 많이 돌리는 것이 아니라
판단의 근거가 남는 실험이다"

다음 6가지는 데이터·모델·실험 설계에서 명확한 근거를 가지고 내린 판단입니다. CH05의 모든 실험은 이 6가지 결정이 옳았는지를 검증하는 흐름으로 설계되었습니다.

01

ARCHITECTURE

단일 모델 대신 2-Stage 채택

305cls × 평균 10장에서 단일 YOLO는 fine-grained 분류 성능이 무너짐. 탐지·분류 역할 분리로 학습 신호 집중.

검증 ▶ Stage 1 mAP 0.99 · Stage 2 Top-1 0.88

02

STAGE 1 BACKBONE

YOLOv26n — 경량 + 최신 안정 버전

단일 클래스 탐지에 nano로 충분. 모바일 이식 가능 + 최신 가용 가중치 + Ultralytics 안정 maintain. 학습 속도 우위.

검증 ▶ mAP@50 0.9947 / 0.9950

03

STAGE 2 BACKBONE

EfficientNetV2-S — 세 후보 비교 후 선택

ResNet50 0.8750 → B2 0.8932 → V2-S 0.8883 (GT Top-1). GT는 비슷하나 Kaggle LB는 0.908 → 0.947 → 0.960으로 명확한 차이 — V2-S 채택.

검증 ▶ Kaggle LB 0.96044 · ResNet50 baseline 대비 +0.052

04

HYPERPARAMETER · PIVOTAL

lr0 = 0.0003 — 백본 교체 후 재조정

Optuna best (lr0=0.000645) 그대로 적용 시 best epoch 33에서 정체. V2-S 구조에 맞춰 0.0003으로 낮추자 best epoch 71로 수렴 경로 개선 — Kaggle 0.95028 → 0.96044.

검증 ▶ Kaggle 0.96044 ★ · best epoch 33→71 · 모델 교체 시 lr 재조정 원칙

05

DATA STRATEGY

External 2차 — 305cls 재구성

56cls 원본 → 305cls 통합. Kaggle 평가 클래스 누락분을 외부 데이터 2차 보강으로 채워 평가 정렬 완성.

검증 ▶ Kaggle 평가 57cls 전체 cover

06

PROCESS

재현성 — seed 42 + 메인 시딩 고정

W2 초기에 시드·라이브러리 버전·하드웨어 환경을 고정. 단, DataLoader 워커 시딩 및

WeightedRandomSampler generator 설정이 누락되어 내부 val 지표는 소폭 변동 가능. Kaggle 제출 결과는 영향 없음.


주의 ▶ 워커 시딩 미완으로 완전한 재현성은 미확보

INTERLUDE • BETWEEN CH 04 & CH 05 04.27 → 05.04 • 7 DAYS

설계와 검증 사이, 7일의 호흡

THE 7-DAY JOURNEY Kaggle Public LB • mAP@[0.75:0.95]

6 submissions • +0.5625 향상



” 큰 변화는 새로운 기술 적용이 아니라,
이미 결정된 6가지가 옳은지 확인하는 과정에서 일어났다.

TEAM 02 • 회고

AI 협업 3원칙 - 우리 팀이 합의한 작업 자세

사전 계획 명확화 · 이해 후 전달 · 흐름 인지의 주체는 사람

PRINCIPLE 01

사전 계획 명확화

AI에게 위임하기 전에 작업 범위·조건·기대값을 사람이 먼저 정의.

PRINCIPLE 02

이해 후 전달

생성된 결과를 그대로 쓰지 않고, 한 번 더 검증·이해한 후 팀에 공유.

PRINCIPLE 03

흐름 인지의 주체는 사람

전체 작업의 맥락과 진행 상황을 파악하는 책임은 항상 사람에게.

NEXT →

END OF INTERLUDE

호흡을 가다듬고, 검증의 장으로

CH 05 · 6가지 결정의 검증

0.96044는 이렇게 만들어졌다

05 설계의 옳음을 실험으로 증명하기

CH04에서 결정한 6가지가 실제 성능으로 검증되었는지 정리합니다.
Stage 1·2 단계 성능부터 Kaggle Public LB 최종 점수까지 모두 기록.

STAGE 1 · 탐지

0.9947

mAP@50 (val · 497장)

YOLOv26n · single class

STAGE 2 · 분류

0.8883

GT Top-1 (val · 305cls)

EfficientNetV2-S · lr0=0.0003

FINAL · KAGGLE

0.96044

Public LB · 57cls 평가

2-Stage E2E Pipeline ★

ALL METRICS - 실험 검증 결과

METRIC	STAGE	VALUE	NOTE
mAP@50 (val · 497장)	Stage 1 (Internal)	0.9947	YOLO val 결과 · single class
mAP@50 (test · 499장)	Stage 1 (Internal)	0.9950	YOLO test 결과 · single class
Internal E2E mAP@50 (val · 305cls 전체)	E2E Pipeline	0.9361	평가 305cls 모두 포함
Internal E2E mAP@50 (test · 305cls 전체)	E2E Pipeline	0.9215	test set · 305cls 전체
GT Top-1 (305cls)	Stage 2 (Internal)	0.8883	분류기 단독 성능
GT Top-5 (305cls)	Stage 2 (Internal)	0.9745	상위 5개 후보 정답률
Kaggle Public LB ★	E2E (Kaggle 57cls)	0.96044	평가 57cls만 채점

NOTES - 수치 해석 가이드

왜 KAGGLE > INTERNAL?

Kaggle은 57cls만 평가. 305cls 학습으로 일반화한 모델이 평가 클래스에서만 채점되니 희소 클래스 영향이 배제되어 점수 상승.

PARAM 수 비교

ResNet50 25.6M · B2 9.1M · V2-S 21.5M. V2-S는 ResNet50보다 작지만 capacity·효율 모두 우위.

GT TOP-1 VS KAGGLE

GT Top-1과 Kaggle LB는 평가 방식이 다름. Kaggle은 detection score 기반 mAP, GT는 분류 정확도.

5-2 2-Phase HPO, 15 trials로 충분했다

Grid → Optuna

01

PHASE 1 · GRID SEARCH

탐색 공간 좁히기 — 12개 조합

SEARCH STRATEGY

lr × ls × wd 격자 탐색

12 조합 × 30 epochs

RANGE EXPLORED

lr0 ∈ {3e-5, 1e-4, 3e-4}

ls ∈ {0, 0.05, 0.1, 0.2}

· wd ∈ {0.001, 0.01}

OUTCOME

lr0=0.0003 구간이 일관되게 우수.

Best: ls=0.05 / wd=0.001. Phase 2의 search space 확정.

0.8786

Best GT Top-1

02

PHASE 2 · OPTUNA TPE

Bayesian 최적화 — 15 trials

SEARCH STRATEGY

Tree-Parzen Estimator

15 trials × 20 epochs

BEST TRIAL · 0008

lr0 = 0.000645

ls = 0.0695 · wd =
0.01013

IMPROVEMENT

Phase 1 대비 +2.91%p

Top-1 0.8786 → 0.9041

0.9041

Best GT Top-1 · trial_0008

INSIGHT · 연휴 속 HPO

"15 trials로도 의미 있는 개선이 가능했다"

연휴(05.04~05.06) 기간 중 자원 한계 안에서 운영.

50 trials 이상 도전을 검토했으나 PM이 "제한된 자원을 다른 검증에 쓰자"고 판단. 결과적으로 0.98 도전 대신 안정적 0.96044 확보.

FINAL LR0 DECISION - V2-S 백본 교체 후 학습률 재조정

FIRST ATTEMPT

0.000645

Optuna best 그대로 적용

best epoch 33에서 정체 · Kaggle 0.95028

RE-TUNED ★

0.0003

백본 구조에 맞춰 재조정

best epoch 33 → 71 · 수렴 경로 개선

RESULT

0.96044

Kaggle Public LB

0.95028 → 0.96044 (+0.010)

학습된 교훈 ▶ 백본을 교체할 때는 이전 HPO 값을 그대로 이식하지 않고, 새 모델의 구조와 수렴 흐름에 맞춰 학습률을 다시 조정해야 한다.


5-3

6번의 제출, 한 번의 도약

04.27 → 05.04

Kaggle Public LB 점수 추이

04.27 첫 제출 0.3979부터 05.04 최종 0.96044까지 — 6번의 제출로 +0.5625 향상



#	DATE	변화 / 이유	SCORE	Δ
P1	04.27 (Sun)	베이스라인 — ResNet50 + 단일 56cls 포맷 문제	0.3979	— first
P2	04.29 (Tue)	submission image_id 포맷 수정	0.68914	+0.291
P3	04.30 (Wed)	305cls 적용 + category_id mapping 수정	0.90845	+0.219
P4	05.03 (Sat)	Stage 2 backbone ResNet50 → EfficientNet-B2 교체	0.94731	+0.039
P5	05.03 (Sat)	Stage 2 backbone B2 → EfficientNetV2-S 교체 (lr0 미조정)	0.95028	+0.003
P6 ★	05.04 (Sun)	lr0 0.0003 재조정 — best epoch 33→71	0.96044	+0.010

OPERATIONAL PRINCIPLES — 실험 운영 4원칙

01

한 번에 한 가지만

매 제출당 1개 변경만 도입.
원인 파악 가능한 구조 유지.

02

근거 기록

제출별 왜·어떻게·결과를
매번 기록. 판단 추적 가능.

03

완벽보다 측정

불완전해도 측정 가능한
형태로 제출. 다음 단계
판단의 근거 확보.

04

재현성 관리

seed 42 + 메인 시딩 고정.
워커 시딩 누락으로 내부 val
소폭 변동 가능 —
Kaggle 제출은 영향 없음.

5-4 남겨진 질문, 다음에 풀어야 할 문제들

limits & roadmap

CURRENT LIMITATIONS - 우리가 풀지 못한 것들 6 limits

데이터 - 각인 유사

외형 비슷 / 각인만 다른 클래스

동일 모양·색상에 각인이나 분할선만 다른 약제는 제한된 데이터로 세밀한 시각 특징을 학습하기 어렵다. 클래스 간 confusion이 잔여 오차의 큰 비중을 차지.

IMPACT Stage 2 분류기의 회복하기 어려운 구조적 한계

아키텍처 - 2-Stage Trade-off

Stage 1 bbox crop 부정확

Stage 1이 알약 각인 부위를 미세하게 잘라낼 경우 Stage 2에 불완전한 crop이 입력. 탐지·분류 분리로 얻은 이점의 반대급부로 함께 관리해야 하는 구조적 trade-off.

IMPACT 분류기 단독 성능 대비 E2E 성능에 ~3%p 갭

데이터 - 소수 클래스

평균 10장 + 환경 다양성 부족

External 병합으로 28배 확대했음에도 fine-grained 분류로는 적은 수치. 조명·배경 변화에 취약하며 Tail 클래스 인식이 Head 대비 명확히 약함.

IMPACT 최소 클래스에서 GT Top-10이 평균 대비 약 5%p 낮음

평가 - 일치도

Internal vs Kaggle 점수 갭

Kaggle 0.96044 vs Internal mAP 0.9361. 평가 클래스 수가 다른 구조적 차이로 두 점수의 직접 비교가 불가능.

IMPACT 실서비스 환경에서의 진짜 성능 추정에 한계

모델 - 추론 환경

모바일 실측 미수행

"경량 모델 채택"은 했으나 실제 모바일 디바이스에서 추론 속도·메모리·배터리 측정은 다음 단계로 미뤄둔 항목.

IMPACT 실용성 검증의 핵심 단계가 보고서 시점에 미완

재현성 - 워커 시딩 미완

DataLoader 워커 시딩 누락

메인 프로세스 시딩(seed 42)은 W2에 고정했으나, DataLoader 워커 8개 및 WeightedRandomSampler generator 시딩이 누락. 내부 val 지표가 run 간 소폭 변동 가능. 프로젝트 종료 직전(05-07) 발견.

IMPACT Kaggle LB 0.96044는 실제 제출이라 영향 없음 · 내부 검증 지표 신뢰도 저하

NEXT STEPS - 다음 사이클에 도전할 것들 4 directions

→ NEXT 01

Domain Shift 대응

손바닥 위 알약, 복잡한 배경, 다양한 조명 등 in-the-wild 데이터 수집·검증. 정제된 데이터셋과 실전 환경 간 성능 갭의 실측이 다음 우선순위.

→ NEXT 02

ONNX 변환 + 모바일 배포

2-Stage 모델을 ONNX 형식으로 경량화하고 iPhone-Android에서 동작하도록 최적화. 추론 시간·정확도 손실·메모리 실측까지 포함하는 완전한 on-device 검증.

→ NEXT 03

Pred bbox 평가 파이프라인

Stage 1이 예측한 bbox crop에 대해 Stage 2 분류 정확도를 직접 측정할 수 있는 구조 마련. 현재의 GT bbox 기준 평가가 가진 2-Stage E2E 갭을 정확히 정량화.

→ NEXT 04

완전한 재현성 확보

worker_init_fn으로 DataLoader 워커별 시딩 + WeightedRandomSampler generator 고정 + CUDA deterministic 설정. 내부 검증 지표의 run 간 일관성 확보.

FINAL REFLECTION

"3주의 학습은 결과 달성이 아니라 판단의 기록을 남기는 일이었다"

Kaggle 0.96044는 결과로서 의미 있지만, 진짜 자산은 **6가지 의사결정과 그 검증 과정**입니다. 다음 사이클에서는 이 기록 위에서 한 단계 더 깊은 질문을 던질 수 있을 것이라 믿습니다.

EPILOGUE · 5 PEOPLE, 1 PROJECT

EP

우리의 3주, 다섯의 시선

0.96044라는 숫자 뒤에는 다섯 사람의 시간이 있었습니다.

각자가 본 풍경을 짧게 남깁니다.



신호정 PM · TECH LEAD

AI 협업 프로젝트를 진행해보는 것은 처음이었지만, 언젠가 시작할 일이라면 지금 해두는 것이 훨씬 좋다는 생각으로 PM을 맡아 역할을 수행했습니다. 클라이언트 개발과 지식의 베이스는 다르지만, 여러 사람들이 협업하는 과정에 필요한 부분들은 여러모로 통하는 것이 많아 제 경험을 다른 시각에서 확장할 수 있는 좋은 기회가 되었습니다. 이 프로젝트를 통해 팀원들 모두가 성장하였다는 것이 느껴져서 좋습니다.



윤승준 MODEL ENGINEER

모델 엔지니어로서 파이프라인을 구축한 이후, 이를 처음 읽는 사람의 관점에서 이해하기 쉽게 전달했어야 했는데 그러지 못한 부분이 아쉬웠습니다. 이번 프로젝트를 통해 다른 프로젝트의 매뉴얼을 참고해 문서화 방향성을 잡아야 한다는 사실을 배웠습니다. 단순히 내 작업을 진행하는 것보다, 어떻게 하면 팀원과 소통하며 협업할 수 있을지에 대해 배운 뜻깊은 시간이었습니다.



김도혁 EXPERIMENTATION LEAD

EL로서 Grid Search 12조합, Optuna 15 trials를 직접 설계하고 Kaggle 제출을 조율하며 전 과정을 관리했습니다. 좋은 실험이란 많이 돌리는 것이 아니라 판단의 근거를 남기는 것임을 배웠습니다. 초반에 내부 검증 지표와 Kaggle 평가 기준의 차이를 제때 공유하지 못한 것이 아쉬웠습니다.



김소원 DATA ENGINEER

데이터 엔지니어로서 데이터 설계 하나하나가 모델 성능에 직결된다는 것을 직접 체감했고, 도메인 특성을 고려한 판단의 중요성을 배웠습니다. 여러 차례 구성이 바뀌는 상황에서도 서로 독려하며 끝까지 함께 해낸 팀 분위기가 가장 기억에 남습니다. 방향성을 먼저 확실하게 하는 것이 팀 전체 속도 면에서 오히려 더 효율적임을 배웠습니다.



방찬우 REPORT & ANALYSIS

보고서를 설계하면서 가장 많이 했던 일은 팀원들의 작업을 읽는 것이었습니다. 각자가 기록한 실험 로그와 의사결정 과정을 하나의 흐름으로 엮으려면, 먼저 그 판단이 왜 내려졌는지를 제가 이해해야 했습니다. 덕분에 직접 모델을 돌리지 않았음에도 파이프라인 전체의 구조를 가장 넓은 시야에서 볼 수 있었습니다. 좋은 보고서란 예쁜 문서가 아니라 읽는 사람이 판단의 맥락까지 따라올 수 있는 문서라는 것을 배웠습니다.

THANK YOU

읽어주셔서 감사합니다. 이 보고서가 다음 사이클의 출발점이 되기를 바랍니다.

— END

PROGRAM · v1.0

GDriveDataShare

한 번의 클릭으로 끝나는 데이터 공유

TECH STACK

- Windows 11
- C# / .NET
- Google Drive API

- THE TRANSFORMATION

4단계 수작업 → 1번의 클릭



AFTER

데이터 공유 = 1번의 클릭



GDriveDataShare 실행 — 압축 + 업로드 + 권한 공유 자동 처리

+ 자동 버전 관리 · + 표준 다운로드 예제 코드 제공

WHY WE BUILT IT - PM의 관점

PM으로서 팀 협업 효율을 떨어뜨리는 병목 구간을 분석하던 중, 가장 번거롭고 인적 실수가 잦은 구간이 '작업용 데이터셋 공유 과정'이었습니다. 촉박한 일정 속에서 AI 코딩 보조 도구를 활용한 **바이브 코딩(대화형 프롬프트 기반 신속 개발)**으로 자동화 프로그램을 빠르게 완성했고, 결과적으로 팀원들이 본연의 핵심 업무에만 집중할 수 있는 환경이 만들어졌습니다.

- 3 KEY FEATURES

- FEATURE 01

원클릭 공유

압축 + 업로드 + 권한 설정이 프로그램 하나로 한 번에 처리.
- FEATURE 02

자동 버전 관리

배포 순서에 따라 파일이 자동 구분 — 데이터 혼선 제거.
- FEATURE 03

표준 다운로드 코드

팀원이 곧바로 사용 가능한 표준 예제 코드 함께 제공.



- WATCH THE DEMO

데모 영상으로 동작 흐름 확인하기

<https://www.youtube.com/watch?v=d6ZBI7Vs80>

QR 스캔 또는 링크 접속 - YouTube